

“CLASIFICACIÓN DE POBREZA EN LIMA Y CALLAO MEDIANTE APRENDIZAJE SUPERVISADO SOBRE MICRODATOS ENAHO”

Autor/Autores: Gael Arias, Integrante 2, Integrante 3

Resumen—Debe contener una descripción muy breve del trabajo, resumiendo el problema que se abordó, el objetivo general, la solución o soluciones planteadas, los resultados obtenidos y la conclusión principal.

[Propuesta inicial:] Este trabajo aborda la clasificación de hogares en situación de pobreza en Lima y Callao mediante algoritmos de aprendizaje supervisado aplicados a microdatos ENAHO (2024–2025). El objetivo es inducir un clasificador binario que identifique hogares vulnerables usando variables observables de vivienda, estructura demográfica e informalidad laboral, minimizando el error de exclusión frente a modelos lineales convencionales.

Se recomienda no exceder 12 líneas; no debe contener citas, abreviaciones o acrónimos; no debe incluir expresiones matemáticas o referencias bibliográficas.

Introducción

Descripción del problema: Contexto, relevancia y justificativa

- **Contexto:** En Lima Metropolitana y el Callao, la pobreza monetaria afecta a cerca del 18 % de los hogares tras los recientes shocks económicos (ENAHO 2024–2025).
- **Problema:** Los sistemas tradicionales de focalización proxy (Proxy Means Testing) utilizan modelos de regresión lineal paramétrica que sufren de subreporte de ingresos informales y generan un alto error de exclusión (falsos negativos).
- **Justificación (IA / Machine Learning):** El problema se formula como una tarea de **Aprendizaje Supervisado de Clasificación Binaria**. A través de un pipeline supervisado, se busca inducir una función de mapeo $f : X \rightarrow Y$ a partir de la experiencia empírica E (microdatos de encuestas) para predecir la condición de pobreza ($Y \in \{0, 1\}$) basándose en atributos observables y verificables del hogar.

Hipótesis y/o pregunta a abordar

- **Pregunta:** ¿En qué medida los algoritmos de clasificación supervisada (Regresión Logística, Árboles de Decisión y Ensamblados) mejoran la detección de hogares en pobreza frente a aproximaciones lineales estándar, considerando el desbalance de clases?
- **Hipótesis:** Un modelo de clasificación no paramétrico (árboles / ensambles) entrenado con preprocesamiento guiado por dominio y ajuste por desbalance incrementará el F_1 -score de la clase minoritaria en al menos 15 puntos porcentuales respecto a una regresión logística simple, reduciendo los falsos negativos por debajo del 20 %.

Objetivos

- **General:** Diseñar, implementar y evaluar un sistema de clasificación binaria supervisada para identificar hogares en condición de pobreza en Lima y Callao usando microdatos ENAHO.
- **Específicos:**
 1. Implementar el pipeline de ingestión y preprocesamiento de datos (resolviendo datos faltantes estructurales por cohabitación en el Módulo 01).

2. Diseñar la ingeniería de características: agregación multinivel (individuo $\rightarrow$ hogar) para módulos de demografía y empleo, y reducción de cardinalidad en categorías de vivienda.
3. Entrenar y comparar algoritmos de clasificación supervisada (Regresión Logística, Árboles de Decisión, Random Forest/Gradient Boosting).
4. Evaluar el rendimiento del clasificador mediante métricas para clases desbalanceadas (F_1 -score, Recall, PR-AUC) y partición temporal (2024 $\rightarrow$ 2025), garantizando control estricto de fuga de datos (*data leakage*).

Trabajos relacionados

Sintetice al menos 3 publicaciones científicas relevantes al problema abordado.

1. **Proxy Means Testing mediante ML:** McBride & Nichols (2018, *World Bank Economic Review*) demostraron que algoritmos de Machine Learning supervisado superan a los estimadores OLS tradicionales en focalización de pobreza, reduciendo significativamente el error de exclusión en muestras fuera de tiempo.
2. **Inferencia de Pobreza con Atributos Observables:** Jean et al. (2016, *Science*) y Blumenstock et al. (2015, *Science*) fundamentan el uso de variables proxy no monetarias para predecir niveles socioeconómicos sin depender de mediciones de consumo de alta volatilidad.
3. **Modelado Tabular y Desbalance de Clases:** Ke et al. (2017, *NeurIPS*) y Fernández et al. (2018, *JAIR*) abordan la optimización de algoritmos supervisados de clasificación sobre datos tabulares heterogéneos y la calibración de umbrales ante distribuciones de clases desbalanceadas.

Metodología

Enfoque(s) propuesto:

Describir formalmente el problema usando una notación adecuada.

- Formalización del Aprendizaje Supervisado (según Tom Mitchell):
 - **Tarea (T):** Clasificación binaria de un hogar en $Y \in \{0, 1\}$ (1: Pobreza total, 0: No Pobre).

- **Experiencia (E):** Conjunto de entrenamiento etiquetado $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$, donde $\mathbf{x}_i \in \mathcal{X} \subset \mathbb{R}^d$ representa el vector de atributos de vivienda, demografía y empleo.
- **Medida de Desempeño (P):** F_1 -score de la clase minoritaria, Recall (sensibilidad) y área bajo la curva Precision-Recall (PR-AUC).

Describir el comportamiento entrada/salida del (los) enfoques.

- **Entrada:** Vector de características $\mathbf{x}_i$ que sintetiza: características físicas de la vivienda (materiales, hacinamiento, saneamiento), variables demográficas del hogar (tamaño, tasa de dependencia) y condiciones laborales del jefe de hogar (informalidad, ocupación).
- **Salida:** Estimación de probabilidad posterior $\hat{p}_i = P(y_i = 1 | \mathbf{x}_i) \in [0, 1]$ y asignación binaria $\hat{y}_i = \mathbb{I}(\hat{p}_i \geq \tau)$, donde τ es el umbral de decisión calibrado.

Describir los operadores/funciones/algoritmos desarrollados para solucionar el problema planteado. No describir métodos genéricos, sino detalles de cómo se aplicó/adaptó al problema.

- **Pipeline Supervisado ENAHO:**
 1. *Limpieza e Imputación Estructural:* Propagación intra-vivienda (ffill/bfill) para resolver el 2.15 % de nulos en hogares secundarios que cohabitan una misma vivienda.
 2. *Agregación Multinivel (Individuo $\rightarrow$ Hogar):* Operador dual $\Phi(\cdot)$ que extrae atributos específicos del jefe de hogar ($P203 = 1$) y calcula agregaciones estadísticas del núcleo (máximo educativo, tasa de ocupación).
 3. *Agrupación Semántica Guiada por Dominio:* Fusión de categorías de baja frecuencia en niveles de calidad habitacional ordenados (e.g. pisos acabados nobles vs cemento básico vs pisos precarios de tierra).
 4. *Algoritmos de Clasificación a Comparar:* Regresión Logística (modelo lineal sigmoidal de referencia), Árboles de Decisión (particiones ortogonales por Gini/Entropía) y Ensamblados (Random Forest / LightGBM).
 5. *Control de Fuga de Datos (Zero Leakage):* Aislamiento absoluto de gastos y líneas de pobreza durante la fase de entrenamiento.

Utilizar figuras para auxiliar la explicación.

[Diagrama del Pipeline de Aprendizaje Supervisado:
Ingesta $\rightarrow$ Preprocesamiento $\rightarrow$ Ingeniería de
Features $\rightarrow$ Modelado Supervisado $\rightarrow$ Validación]

Experimentación y Resultados

Setup experimental:

Describir datos usados (o método para obtenerlos) (si aplica).

Describir las métricas de evaluación.

Describir los experimentos hechos (qué componentes/parámetros/escenarios se probaron, qué valores, qué estrategia de validación).

Los experimentos deben ser planificados para poder caracterizar/comparar los enfoques desarrollados. Aquí algunas preguntas que deben responder los experimentos:

¿El enfoque desarrollado resuelve siempre el problema?

¿Qué tan eficientemente lo resuelven?

¿Cuál es el desempeño comparado con otros modelos o técnicas de referencia?

¿Cómo influyen los parámetros del enfoque en su desempeño?

Resultados y Discusión:

Presentar resultados numéricos generados en los experimentos. Hacer un análisis de dichos resultados.

La presentación de los resultados debe facilitar el entendimiento. En general se deben usar figuras y/o tablas. Recuerde, todos los resultados deben interpretarse. Esforzarse para explicar el formato de las curvas presentadas, dar detalles del tiempo de simulación.

Conclusión

Dar las conclusiones principales con base en los resultados obtenidos y a lo que fue planteado en su hipótesis, ¿qué se puede decir del o los enfoques desarrollados y/o del problema abordado?

Sugerencias de trabajos futuros

Indicar, por ejemplo: ¿qué cosas se pueden mejorar del enfoque?, ¿qué otros posibles problemas podrían abordarse con el enfoque?

Implicancias éticas

Indicar qué implicancias éticas podría generar el trabajo desarrollado de ser escalado (sesgos, posible afectación a la seguridad/privacidad de usuarios, posibilidad de ataques y robo de datos, etc). Sugiera formas de abordar dichos problemas

Link del repositorio del trabajo

Puede ser Github, Gitlab, u otro. Dar las credenciales para poder tener acceso.

Declaración de contribución de cada integrante

Describir los aportes de cada integrante al proyecto.

Declaración de uso de IA

Indicar si se emplearon herramientas de inteligencia artificial durante el desarrollo del trabajo. En caso afirmativo, especificar la herramienta utilizada, el propósito de su uso y la forma en que sus aportes fueron revisados, validados e integrados por el grupo. Precisar que la responsabilidad del contenido final recae en los autores.

Referencias

Ejemplo:

Víctor O.K. Li, "Hints on writing technical papers and

making presentations”, IEEE Transactions on Education, vol. 42, no. 2, pp. 134-137, mayo de 1999.

Robert M. Woelfle, editor, “New Guide for Better Technical Presentations: Applying Proven Techniques with Modern Tools”, IEEE Professional Communication Society, 1992. Dirección electrónica: www.ieee.org

Nota importante:

Figuras y tablas

Cada figura debe ser leída y comprendida sin necesidad de recurrir a la descripción a lo largo del texto.

Todos los símbolos usados deben ser explicados en la leyenda.