

“CLASIFICACIÓN DE POBREZA EN LIMA Y CALLAO MEDIANTE APRENDIZAJE SUPERVISADO SOBRE MICRODATOS ENAHO”

Autores: Gael Arias, Valeshka Lavado, Melanie Mallqui, Franco Salcedo

Resumen—Este trabajo aborda la identificación y clasificación de hogares en situación de pobreza monetaria en Lima Metropolitana y el Callao mediante el desarrollo de un sistema de aprendizaje supervisado aplicado a microdatos multimodulares de la Encuesta Nacional de Hogares (ENAHO 2024–2025). Ante la inobservabilidad de ingresos informales y las limitaciones de los modelos lineales tradicionales de focalización, se formula un pipeline con operadores específicos de imputación intra-predio, agregación multinivel y agrupación semántica por dominio, evaluando una jerarquía de clasificadores optimizados con funciones de pérdida sensibles al costo. El objetivo es maximizar la detección de hogares vulnerables y mitigar el error de exclusión social bajo un esquema estricto de validación temporal fuera de tiempo.

Introducción

Descripción del problema: Contexto, relevancia y justificativa

En Lima Metropolitana y la Provincia Constitucional del Callao, la pobreza monetaria urbana afecta al 28.2 % de la población según cifras oficiales del INEI (2024), lo cual equivale al 18.61 % de los hogares muestreados en la Encuesta Nacional de Hogares (ENAHO 2024). Este fenómeno socioeconómico se configura como una «pobreza urbana cara» (IEP, 2023), condicionada por una tasa de empleo informal del 57.3 % (INEI, 2024) que genera una profunda volatilidad e inestabilidad en los flujos de ingresos cotidianos de las familias.

Históricamente, los mecanismos estatales de asignación de subsidios y programas sociales mediante *Proxy Means Testing* (SISFOH), basados en regresiones lineales por Mínimos Cuadrados Ordinarios (MCO), han mostrado severas limitaciones de focalización en entornos metropolitanos. En los microdatos de la ENAHO 2024, se comprueba que el 71.26 % de los hogares en situación de pobreza en Lima y Callao (739 de 1,037 familias) no reciben ninguna transferencia pública monetaria ni programas de apoyo alimentario, configurando un crítico error de exclusión social. Asimismo, producto de décadas de autoconstrucción progresiva informal (GRADE, 2024), el 59.4 % de los hogares pobres habita viviendas con paredes consolidadas de ladrillo o cemento y el 79.5 % cuenta con pisos de cemento o loseta. Este hallazgo empírico invalida por completo el uso de reglas habitacionales univariadas simples y exige capturar interacciones no lineales multidimensionales.

Ante esta problemática, se formula la identificación de hogares vulnerables como un problema de **Aprendizaje Supervisado de Clasificación Binaria** fundamentado en proxies observables de vivienda, estructura demográfica, educación e informalidad laboral. Se prioriza la clasificación discreta sobre la regresión continua para evitar que la asimetría en las colas superiores de ingresos distorsione la frontera crítica de vulnerabilidad bajo funciones de error cuadrático medio (MSE).

Hipótesis y/o pregunta a abordar

Frente al diagnóstico presentado, la investigación plantea la siguiente pregunta central: ¿En qué medida un sistema de aprendizaje supervisado basado en modelos de árboles (CART, Random Forest y Gradient Boosting), integrando proxies observables habitacionales con la composición demográfica y laboral del hogar, supera a los modelos lineales tradicionales en la detección de po-

breza y reducción del error de exclusión en Lima y Callao bajo una evaluación temporal fuera de tiempo (2024 → 2025)?

Como hipótesis principal de trabajo, se postula que los clasificadores no lineales de ensamble basados en árboles, optimizados mediante una función de pérdida sensible al costo, superarán a la Regresión Logística lineal en al menos 12 puntos porcentuales de F_1 -score en la clase minoritaria, reduciendo el error de exclusión por debajo del 30 % ($\text{Recall} \geq 70\%$) al evaluarse ciegamente de forma fuera de tiempo sobre la muestra de la ENAHO 2025.

Objetivos

En concordancia con la problemática y las hipótesis formuladas, el **objetivo general** del proyecto consiste en desarrollar y evaluar comparativamente un sistema de clasificación binaria supervisado basado en modelos de árboles, integrando microdatos multidimensionales de la ENAHO, para optimizar la identificación de hogares en pobreza y mitigar asimétricamente el error de exclusión social en Lima Metropolitana y Callao bajo validación temporal fuera de tiempo (2024 → 2025).

Para alcanzar este fin, se definen cuatro **objetivos específicos**:

1. Construir e implementar un pipeline modular de datos bajo principios SOLID que resuelva los nulos estructurales por cohabitación intra-vivienda e integre de forma consistente los módulos 01, 02, 03, 05 y 34 de la ENAHO.
2. Diseñar la ingeniería de características mediante un operador de agregación relacional de individuo a hogar y un agrupamiento semántico por dominio en variables habitacionales para controlar la dispersión sin perder señal predictiva.
3. Entrenar y optimizar la jerarquía de modelos del curso (Regresión Logística ElasticNet, CART, Random Forest y LightGBM) aplicando funciones de pérdida sensibles al costo ($c_1 \gg c_0$) que reflejen el desbalance empírico de clases.
4. Evaluar el rendimiento en un esquema ciego fuera de tiempo (2024 → 2025) mediante métricas de desbalance (F_1 -score, PR-AUC, Recall) y auditar las contribuciones no lineales de las variables mediante TreeSHAP.

Trabajos relacionados

La literatura científica sobre focalización socioeconómica y aprendizaje automático ofrece fundamentos empíricos y algorítmicos determinantes para este estudio. En primer lugar, en el ámbito de la focalización y reducción del error de exclusión, Aiken et al. [1] demostraron en *Nature* que el aprendizaje supervisado sobre proxies observables no monetarios reduce la tasa de error de exclusión en transferencias sociales entre un 4 % y un 21 % frente a los padrones gubernamentales estáticos durante crisis humanitarias. Este hallazgo valida la sustitución de registros administrativos lentos por modelos de inferencia basados en privaciones tangibles.

En segundo lugar, respecto al sesgo inductivo y la selección de arquitecturas tabulares, Grinsztajn et al. [2] probaron empíricamente en NeurIPS sobre 45 conjuntos de datos que los modelos basados en árboles (CART, Random Forest y Gradient Boosting) superan sistemáticamente a las arquitecturas de Deep Learning en datos tabulares heterogéneos. La naturaleza escalonada de las funciones de decisión y la invarianza a transformaciones monótonas justifican el uso preferente de ensambles arbóreos para procesar encuestas de hogares.

En tercer lugar, en cuanto al fallo estructural de las fórmulas convencionales de Proxy Means Testing (PMT), McBride & Nichols [3] evidenciaron en *The World Bank Economic Review* que las aproximaciones basadas en regresión lineal (MCO) sufren de sobreajuste severo y se degradan drásticamente fuera de muestra. Sus experimentos comprobaron que los modelos no lineales reducen la exclusión social entre un 10 % y un 18 %, al capturar interacciones multidimensionales de privación que los supuestos aditivos lineales ignoran.

Finalmente, en relación con la estabilidad temporal de los modelos, el estudio conjunto del Banco Mundial y EAAMO [4] demostró que los clasificadores de pobreza sufren una degradación sistemática por desplazamiento de distribución (*data drift*) ante fluctuaciones macroeconómicas. Los autores concluyeron que la validación cruzada aleatoria convencional sobrestima el rendimiento debido a la fuga temporal, exigiendo un protocolo riguroso de evaluación fuera de tiempo (*train* en t y *test* ciego en $t + 1$).

Metodología

Formalización del problema de aprendizaje

El problema se formaliza bajo el marco canónico de Aprendizaje Supervisado de Tom Mitchell (1997) mediante la terna $\langle T, E, P \rangle$. La **Tarea (T)** corresponde a la inducción de una regla de decisión binaria $f : \mathcal{X} \rightarrow \mathcal{Y}$ que asigna a cada hogar i una etiqueta $y_i \in \{0, 1\}$, donde $y_i = 1$ denota que el hogar se encuentra en situación de pobreza total (extrema o no extrema) y $y_i = 0$ corresponde a la condición de no pobreza, de acuerdo con la clasificación oficial del Módulo 34 (Sumaria) del INEI.

La **Experiencia (E)** se define a través de un conjunto finito de entrenamiento etiquetado $\mathcal{D}_{\text{train}} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{N_{\text{train}}}$, correspondiente a $N_{\text{train}} = 5,571$ hogares observados en Lima Metropolitana y Callao en la ENAHO 2024. Este dominio presenta un marcado desbalance empírico: 1,037 hogares pobres (18.61 %) frente a 4,534 hogares no pobres (81.39 %), estableciendo una razón de desbalance $\gamma \approx 4,372$ a 1.

Dada esta asimetría y el elevado costo ético de omitir a familias en vulnerabilidad, la **Medida de Desempeño (P)** prioriza el F_1 -score de la clase minoritaria, el área bajo la curva Precision-Recall (PR-AUC) y la sensibilidad ($\text{Recall} \geq 0,70$). Consecuentemente, el proceso de optimización minimiza una función de pérdida logística sensible al costo (*Cost-Sensitive Loss*):

$$\mathcal{L}_{\text{CS}}(\theta) = -\frac{1}{N} \sum_{i=1}^N [c_1 y_i \log(\hat{p}_i) + c_0 (1 - y_i) \log(1 - \hat{p}_i)] + \lambda \Omega(\theta) \quad (1)$$

donde los ponderadores $c_1 = 4,372$ y $c_0 = 1,0$ penalizan asimétricamente el error de exclusión social (falso negativo) respecto al error de inclusión presupuestal (falso positivo).

Diagnóstico exploratorio inicial y sustento de operadores

Para fundamentar rigurosamente el diseño del pipeline y evitar transformaciones arbitrarias, el Análisis Exploratorio de Datos (EDA) inicial identificó tres patologías estructurales en los microdatos:

En primer lugar, se detectó que el 2.15 % de las familias corresponden a hogares secundarios (HOGAR 22, 33...) que cohabitan en un mismo predio físico y cuyos materiales no son re-encuestados por omisión de diseño del INEI. Este hallazgo empírico justifica el diseño de un operador de propagación intra-predio en lugar de eliminar observaciones o imputar medias globales.

En segundo lugar, se comprobó una severa discrepancia de granularidad relacional: mientras el hábitat se registra por hogar, los módulos de demografía, educación y empleo contienen 19,420 individuos con roles asimétricos (el 57.3 % de jefes de hogar labora en la informalidad), lo que exige desacoplar las variables del sostén principal de los funcionales agregados de carga familiar.

En tercer lugar, como evidencia la Figura 1, variables categóricas como material de pisos (P103) exhiben colas largas con frecuencias menores al 0.8 % (mármol 0.2 %, caña 0.5 %, madera rústica 0.8 %). Una codificación ciega por *One-Hot Encoding* induciría hiperdispersión y sobreajuste. Al consolidar estas categorías en tres estratos semánticos (noble acabado, cemento básico y precario), se comprueba una relación monótona creciente con la tasa empírica de pobreza (7.1 %, 24.3 % y 37.0 %), fundamentando el operador *DomainBinner*.

En cuarto lugar, dado el predominio de variables cualitativas, la correlación de Pearson resulta inaplicable por asumir relaciones lineales continuas. El diagnóstico analiza la redundancia entre covariables mediante la V de Cramér ($V \in [0, 1]$) podando pares con $V > 0,80$, y evalúa la capacidad discriminante no lineal respecto al target mediante Información Mutua $I(X; Y)$. Bajo este criterio, se descartó una reducción factorial continua densa (PCA o FAMD) debido a que rotar el espacio tabular diluye las señales discretas requeridas por las particiones ortogonales de los árboles y elimina la explicabilidad univariada de políticas públicas (TreeSHAP). En su lugar, la reducción de dimensionalidad se formula como una selección curada en tres etapas que comprime las > 400 variables originales a un vector óptimo e interpretable de $d \approx 20$ dimensiones.




Figura 1: **Diagnóstico EDA Inicial y Justificación de Agrupación Semántica.** (a) Distribución hiperdispersa en categorías oficiales del INEI. (b) Estratos consolidados que revelan monotonía creciente con la pobreza monetaria.

Espacio de entrada, salida y política de cero fuga

La unidad muestral de análisis e inferencia es el hogar urbano, identificado por la clave compuesta (CONGLOME, VIVIENDA, HOGAR). El espacio de entrada $\mathcal{X} \subset \mathbb{R}^d$ se estructura mediante la concatenación de cuatro subvectores modulares $\mathbf{x}_i = [\mathbf{x}_i^{(viv)}, \mathbf{x}_i^{(dem)}, \mathbf{x}_i^{(educ)}, \mathbf{x}_i^{(emp)}]^T$: el subvector de vivienda (Módulo 01) captura materiales físicos, abastecimiento de agua por red pública, saneamiento y hacinamiento; el subvector demográfico (Módulo 02) sintetiza el tamaño del hogar, presencia de infantes y tasas de dependencia etaria; el subvector de educación (Módulo 03) registra los años de escolaridad y máximo nivel educativo familiar; y el subvector laboral (Módulo 05) modela la condición de informalidad, tenencia de pensión y tasa de ocupación.

Bajo un estricto principio de aislamiento (*Zero Data Leakage*), toda variable financiera de ingresos, gastos brutos y líneas de corte monetario de Sumaria queda excluida del espacio $\mathcal{X}$. El espacio de salida opera en dos etapas: primero, el modelo genera una estimación probabilística continua $\hat{p}_i = P(y_i = 1 | \mathbf{x}_i) \in [0, 1]$; posteriormente, se aplica una regla de decisión $\hat{y}_i = \mathbb{I}(\hat{p}_i \geq \tau^*)$, donde el umbral operativo $\tau^* \approx 0,30$ se calibra empíricamente en validación interna para maximizar el F_1 -score sujeto a garantizar una cobertura de pobreza $\text{Recall} \geq 0,70$.

Operadores de ingeniería y clasificadores adaptados

A partir de los hallazgos del EDA inicial se implementaron los siguientes operadores modulares:

En primer término, el operador `HousingCohortImputer` propaga los materiales del hogar principal a hogares secundarios mediante `ffill().bfill()` sobre la clave (CONGLOME, VIVIENDA), resolviendo el 100 % de los nulos de cohabitación sin inventar registros sintéticos.

En segundo término, el operador relacional $\Phi(\cdot)$ (`HouseholdAggregator`) colapsa la tabla de personas ($1 : M$) bifurcando el flujo: extrae los atributos directos del jefe ($P203 = 1$) y computa funcionales estadísticos colectivos (tasa de dependencia etaria, máximo nivel educativo y porcentaje de ocupados).

En tercer término, el operador `DomainBinner` proyecta las variables de alta dispersión sobre los estratos semánticos monótonos validados en el diagnóstico exploratorio.

Finalmente, la jerarquía de modelos evaluados comprende: una Regresión Logística ElasticNet (L_1/L_2) como referencia lineal; un Árbol de Decisión CART con poda por costo-complejidad; un ensamble Random Forest con reducción de varianza; y un clasificador LightGBM con crecimiento por hojas (*leaf-wise*) y ponderación directa de gradientes (`scale_pos_weight = 4.372`), adaptado para inducir fronteras de decisión no lineales ante la informalidad metropolitana.

1. Ingesta Multimodular ENAHO (INEI 2024–2025)

- Mód. 01: Vivienda (materiales, agua, saneamiento) [Hogar]
- Mód. 02, 03, 05: Demografía, educación y empleo [Persona]
- Mód. 34: Sumaria $\rightarrow$ Etiqueta binaria $y_i \in \{0, 1\}$

2. Operadores de Ingeniería y Reducción Curada

- `HousingCohortImputer`: Imputación intra-predio (`ffill/bfill`).
- `HouseholdAggregator` $\Phi(\cdot)$: Rama Jefe ($P203 = 1$) y núcleo familiar.
- `DomainBinner` y Curaduría ($d \approx 20$): Poda $V > 0,80$ e $I(X; Y)$.
- **Cortafuegos Cero Fuga**: Aislamiento total de ingresos y gastos.

3. Espacio Vectorial y Modelado Supervisado

- Vector: $\mathbf{x}_i \in \mathbb{R}^d$ ($N = 5,571$ hogares, desbalance 1:4.37).
- Modelos: Regresión Logística $\rightarrow$ CART $\rightarrow$ Random Forest $\rightarrow$ LightGBM (*Cost-Sensitive*, `scale_pos_weight = 4.372`).

4. Inferencia y Validación Fuera de Tiempo

- Probabilidad continua: $\hat{p}_i = P(y_i = 1 | \mathbf{x}_i) \in [0, 1]$.
- Regla de decisión: $\hat{y}_i = \mathbb{I}(\hat{p}_i \geq \tau^*)$ con $\tau^* \approx 0,30$ ($\text{Recall} \geq 70\%$).
- Validación *Out-of-Time*: Train 2024 $\rightarrow$ Blind Test 2025.

Figura 2: **Arquitectura del Pipeline de Clasificación Supervisada de Pobreza Urbana.** Flujo secuencial modular desde la ingesta de encuestas hasta la evaluación temporal fuera de tiempo, integrando operadores específicos para mitigar las fricciones empíricas detectadas en el EDA inicial.

Experimentación y Resultados

[Sección a desarrollar en el Entregable Final conforme al protocolo de entrenamiento sobre la ENAHO 2024 y evaluación ciega fuera de tiempo sobre la ENAHO 2025.]

Conclusión

[Sección a desarrollar en el Entregable Final tras la obtención y contraste de los resultados experimentales frente a las hipótesis.]

Sugerencias de trabajos futuros

[Sección a desarrollar en el Entregable Final.]

Implicancias éticas

[Sección a desarrollar en el Entregable Final, abordando equidad algorítmica, sesgo de exclusión y privacidad de los microdatos.]

Link del repositorio del trabajo

El código fuente del pipeline, scripts de ingeniería de características, cuadernos de experimentación y artefactos de reproducibilidad se encuentran alojados en el repositorio oficial:

<https://github.com/usuario/pucp-ia-tarea-academica>

Declaración de contribución de cada integrante

Gael Arias (2021XXXX): Arquitectura de software modular del pipeline de datos, diseño de validadores de esquema bajo principios SOLID, formalización matemática del problema de aprendizaje supervisado y tipografía del informe modular en $\text{\LaTeX}$.

Valeshka Lavado (2021XXXX): Revisión sistemática de literatura sobre focalización y Proxy Means Testing, procesamiento de microdatos de vivienda (Módulo 01) e ingeniería de agregación multinivel en demografía (Módulo 02).

Melanie Mallqui (2021XXXX): Implementación de la función de pérdida sensible al costo, extracción del módulo de informalidad laboral (Módulo 05) y diseño de la agrupación semántica por dominio.

Franco Salcedo (2021XXXX): Diseño del protocolo de validación temporal fuera de tiempo (2024 $\rightarrow$ 2025), análisis exploratorio de datos (EDA) y redacción del marco experimental.

Declaración de uso de IA

Durante el desarrollo del trabajo se emplearon asistentes basados en modelos de lenguaje (Claude / ChatGPT) con fines exclusivos de soporte sintáctico en la depuración de scripts en Python, formateo de macros en $\text{\LaTeX}$ y verificación formal de referencias bibliográficas en estándar IEEE. Todo el diseño metodológico, la formulación matemática, el procesamiento de datos de la ENAHO y el análisis de resultados fueron concebidos, auditados y validados íntegramente por los autores, sobre quienes recae la responsabilidad absoluta del contenido del informe.

Referencias

- [1] E. Aiken, S. Bellue, D. Karlan, C. Udry, and J. Blumensstock, "Machine learning and phone data can improve targeting of humanitarian aid," *Nature*, vol. 603, no. 7903, pp. 864–870, 2022.
- [2] L. Grinsztajn, E. Oyallon, and G. Varoquaux, "Why do tree-based models still outperform deep learning on tabular data?" in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, 2022, pp. 507–520.
- [3] L. McBride and A. Nichols, "Retooling poverty targeting using out-of-sample machine learning and proxy means tests," *The World Bank Economic Review*, vol. 32, no. 3, pp. 531–550, 2018.
- [4] World Bank and EAAMO, "Moving targets: When does a poverty prediction model need to be updated?" in *Proceedings of the 3rd ACM Conference on Equity and Access in Algorithms, Mechanisms, and Optimization (EAAMO)*, 2023, pp. 1–12.