

“CLASIFICACIÓN DE POBREZA EN LIMA Y CALLAO MEDIANTE APRENDIZAJE SUPERVISADO SOBRE MICRODATOS ENAHO”

Autor/Autores: Gael Arias, Integrante 2, Integrante 3

Resumen—Debe contener una descripción muy breve del trabajo, resumiendo el problema que se abordó, el objetivo general, la solución o soluciones planteadas, los resultados obtenidos y la conclusión principal.

[Propuesta inicial:] Este trabajo aborda la clasificación de hogares en situación de pobreza en Lima y Callao mediante algoritmos de aprendizaje supervisado aplicados a microdatos ENAHO (2024–2025). El objetivo es inducir un clasificador binario que identifique hogares vulnerables usando variables observables de vivienda, estructura demográfica e informalidad laboral, minimizando el error de exclusión frente a modelos lineales convencionales.

Se recomienda no exceder 12 líneas; no debe contener citas, abreviaciones o acrónimos; no debe incluir expresiones matemáticas o referencias bibliográficas.

Introducción

Descripción del problema: Contexto, relevancia y justificativa

- **Contexto:** En Lima Metropolitana y el Callao, la pobreza monetaria urbana afecta a cerca del 18.6 % de los hogares (ENAHO 2024–2025). La volatilidad de ingresos en economías urbanas altamente informales dificulta la medición oportuna de la vulnerabilidad.
- **Problema de la Focalización Clásica:** Los sistemas tradicionales de Proxy Means Testing (PMT) basados en regresiones lineales por MCO (como el SISFOH) asumen aditividad rígida y sufren por el subreporte de ingresos informales, generando un alto *error de exclusión social* (falsos negativos).
- **Justificación de la IA:** Se formula el problema como **Aprendizaje Supervisado de Clasificación Binaria** sobre atributos observables y verificables de la vivienda, demografía y empleo informal, induciendo $f : \mathcal{X} \rightarrow \mathcal{Y}$ a partir de microdatos de encuestas multi-*anuales*.
- **Decisión Arquitectónica:** Se prioriza la clasificación binaria directa sobre la regresión continua de gasto para evitar que la varianza desproporcionada de hogares de altos ingresos distorsione la frontera crítica de pobreza bajo funciones de costo cuadráticas (*MSE*).

Hipótesis y/o pregunta a abordar

- **Pregunta:** ¿En qué medida un pipeline de aprendizaje automático supervisado basado en clasificadores no lineales (Gradient Boosted Decision Trees), adaptado con reducción dimensional semántica y optimización sensible al costo, supera a los modelos lineales de PMT en la identificación de hogares pobres en Lima y Callao?
- **Hipótesis:** Un modelo de ensamble no paramétrico (LightGBM/XGBoost) entrenado sobre un espacio de características multidimensional consolidado (Vivienda, Demografía, Educación y Empleo informal), con preprocesamiento guiado por dominio y ajuste por desbalance de clases, incrementará el F_1 -score de la clase minoritaria en al menos 15 puntos porcentuales respecto a la Regresión Logística, reduciendo el error de exclusión por debajo del 20 % en evaluación fuera de tiempo (2024 → 2025).

Objetivos

- **General:** Diseñar, implementar y evaluar un sistema de clasificación binaria supervisado basado en ensamblajes de árboles para clasificar la condición de pobreza en hogares de Lima y Callao usando microdatos ENAHO.
- **Específicos:**
 1. Construir un pipeline modular de ingestión y limpieza bajo principios SOLID para resolver datos faltantes estructurales por cohabitación en los módulos 01, 02, 03, 05 y 34.
 2. Diseñar la ingeniería de características mediante agregación multinivel (individuo → hogar) y agrupación semántica por dominio (*Domain-based Binning*) para mitigar la dispersión en colas largas.
 3. Entrenar y comparar clasificadores supervisados (Regresión Logística baseline, Árboles CART, Random Forest y LightGBM) incorporando pérdidas sensibles al costo.
 4. Evaluar el rendimiento mediante métricas para clases desbalanceadas (F_1 -score, Recall, PR-AUC) y partición temporal (2024 → 2025), garantizando control estricto de fuga de datos (*data leakage*) y explicabilidad con TreeSHAP.

Trabajos relacionados

Sintetice al menos 3 publicaciones científicas relevantes al problema abordado.

1. **Proxy Means Testing mediante ML:** McBride & Nichols [1] compararon modelos MCO tradicionales contra algoritmos de Machine Learning (Lasso, Random Forest y Gradient Boosting) en encuestas de hogares de tres países en desarrollo. Demostraron que los modelos no lineales reducen la tasa de error de exclusión social entre un 10 % y un 18 % en muestras fuera de tiempo (*out-of-sample*), justificando el abandono de supuestos aditivos lineales rígidos en la focalización de programas sociales.
2. **Inferencia de Pobreza con Proxies Observables:** Jean et al. [2] y Blumenstock et al. [3] sentaron las bases para predecir niveles socioeconómicos y consumo mediante variables observables indirectas. Sus hallazgos comprueban que las características físicas de la vivienda y el acceso a servicios básicos actúan

como estimadores robustos del ingreso permanente, eludiendo el sesgo y la volatilidad de los ingresos monetarios de corto plazo.

3. **Modelado Tabular y Desbalance de Clases:** Ke et al. [4] formularon la arquitectura LightGBM optimizada para datos tabulares heterogéneos mediante particiones eficientes por hojas. Por su parte, Fernández et al. [5] demostraron que en datos tabulares con interacciones complejas, el aprendizaje sensible al costo (*Cost-Sensitive Learning*) y el ajuste de umbrales (*Threshold Moving*) son preferibles al remuestreo sintético para mitigar el desbalance de clases sin distorsionar la distribución natural de los atributos.

Metodología

Enfoque(s) propuesto:

Describir formalmente el problema usando una notación adecuada.

- Siguiendo el paradigma de Aprendizaje Supervisado (Mitchell, 1997):
 - **Tarea (T):** Clasificación binaria que asigna a cada hogar i una etiqueta $y_i \in \{0, 1\}$ (1: Pobreza total, 0: No Pobre).
 - **Experiencia (E):** Conjunto de entrenamiento etiquetado $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$, donde $\mathbf{x}_i \in \mathcal{X} \subset \mathbb{R}^d$ sintetiza atributos de vivienda, demografía y empleo informal.
 - **Medida de Desempeño (P):** F_1 -score minoritario, Recall de la clase pobre y área bajo la curva Precision-Recall (PR-AUC).
- **Pérdida Sensible al Costo:** Se optimiza una pérdida asimétrica $\mathcal{L}(\theta) = -\sum_{i=1}^N [c_1 y_i \log(\hat{p}_i) + c_0 (1 - y_i) \log(1 - \hat{p}_i)]$ con $c_1 > c_0$ para penalizar fuertemente el error de exclusión (Falso Negativo).

Describir el comportamiento entrada/salida del (los) enfoques.

- **Entrada:** Vector de características $\mathbf{x}_i$ que sintetiza: características físicas de la vivienda (materiales, hacinamiento, saneamiento), variables demográficas agregadas del hogar (tamaño, tasa de dependencia) y condiciones laborales del jefe de hogar (informalidad, afiliación a pensión).
- **Salida:** Estimación de probabilidad posterior $\hat{p}_i = P(y_i = 1 \mid \mathbf{x}_i) \in [0, 1]$ y asignación binaria $\hat{y}_i = \mathbb{I}(\hat{p}_i \geq \tau)$, donde el umbral τ se optimiza para maximizar el F_1 -score.

Describir los operadores/funciones/algoritmos desarrollados para solucionar el problema planteado. No describir métodos genéricos, sino detalles de cómo se aplicó/adaptó al problema.

- **1. Imputación por Cohabitación Intra-Vivienda:** Propagación intra-vivienda (ffill/bfill por CONGLOME y VIVIENDA) para resolver el 2.15% de nulos estructurales en hogares secundarios que comparten la misma unidad física.

- **2. Agregación Multinivel (Individuo → Hogar):** Operador dual $\Phi(\cdot)$ que extrae variables directas del jefe de hogar ($P_{203} = 1$) y calcula agregaciones estadísticas del núcleo familiar (tasa de dependencia demográfica, porcentaje de ocupados, máximo nivel educativo).
- **3. Agrupación Semántica Guiada por Dominio:** Consolidación de categorías con colas largas ($< 1\%$) en grupos de calidad habitacional ordenados (e.g., piso noble acabado vs cemento básico vs tierra), evitando dispersión sin perder señal discriminante.
- **4. Algoritmos a Comparar:** Regresión Logística (baseline sigmoidal penalizado), Árboles de Decisión CART (particiones ortogonales por Gini/Entropía), Random Forest y LightGBM (ensamble por boosting).
- **5. Control de Fuga de Datos (Zero Leakage):** Aislamiento absoluto de gastos de consumo y líneas de pobreza de Sumaria en la matriz de entrenamiento $\mathbf{x}_i$.

Utilizar figuras para auxiliar la explicación.

[Diagrama del Pipeline Supervisado: Ingesta → Agregación Multinivel → Domain Binning → GBDT Cost-Sensitive → Validación Out-of-Time]

Experimentación y Resultados

Setup experimental:

Describir datos usados (o método para obtenerlos) (si aplica).

Describir las métricas de evaluación.

Describir los experimentos hechos (qué componentes/parámetros/escenarios se probaron, qué valores, qué estrategia de validación).

Los experimentos deben ser planificados para poder caracterizar/comparar los enfoques desarrollados. Aquí algunas preguntas que deben responder los experimentos:

¿El enfoque desarrollado resuelve siempre el problema?

¿Qué tan eficientemente lo resuelven?

¿Cuál es el desempeño comparado con otros modelos o técnicas de referencia?

¿Cómo influyen los parámetros del enfoque en su desempeño?

Resultados y Discusión:

Presentar resultados numéricos generados en los experimentos. Hacer un análisis de dichos resultados.

La presentación de los resultados debe facilitar el entendimiento. En general se deben usar figuras y/o tablas. Recuerde, todos los resultados deben interpretarse. Esforzarse para explicar el formato de las curvas presentadas, dar detalles del tiempo de simulación.

Conclusión

Dar las conclusiones principales con base en los resultados obtenidos y a lo que fue planteado en su

hipótesis, ¿qué se puede decir del o los enfoques desarrollados y/o del problema abordado?

Sugerencias de trabajos futuros

Indicar, por ejemplo: ¿qué cosas se pueden mejorar del enfoque?, ¿qué otros posibles problemas podrían abordarse con el enfoque?

Implicancias éticas

Indicar qué implicancias éticas podría generar el trabajo desarrollado de ser escalado (sesgos, posible afectación a la seguridad/privacidad de usuarios, posibilidad de ataques y robo de datos, etc). Sugiera formas de abordar dichos problemas

Link del repositorio del trabajo

Puede ser Github, Gitlab, u otro. Dar las credenciales para poder tener acceso.

Declaración de contribución de cada integrante

Describir los aportes de cada integrante al proyecto.

Declaración de uso de IA

Indicar si se emplearon herramientas de inteligencia artificial durante el desarrollo del trabajo. En caso afirmativo, especificar la herramienta utilizada, el propósito de su uso y la forma en que sus aportes fueron revisados, validados e integrados por el grupo. Precisar que la responsabilidad del contenido final recae en los autores.

Referencias

Ejemplo:

Victor O.K. Li, "Hints on writing technical papers and making presentations", IEEE Transactions on Education, vol. 42, no. 2, pp. 134-137, mayo de 1999.

Robert M. Woelfle, editor, "New Guide for Better Technical Presentations: Applying Proven Techniques with Modern Tools", IEEE Professional Communication Society, 1992. Dirección electrónica: www.ieee.org

Referencias

- [1] L. McBride and A. Nichols, "Retooling poverty targeting using out-of-sample machine learning and proxy means tests," *The World Bank Economic Review*, vol. 32, no. 3, pp. 531-550, 2018.
- [2] N. Jean, M. Burke, M. Sherrie, S. Ermon, D. B. Lobell, and S. Biswas, "Combining satellite imagery and machine learning to predict poverty," *Science*, vol. 353, no. 6301, pp. 790-794, 2016.
- [3] J. Blumenstock, G. Cadamuro, and R. On, "Predicting poverty and wealth from mobile phone metadata and machine learning," *Science*, vol. 350, no. 6264, pp. 1073-1076, 2015.
- [4] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "Lightgbm: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, pp. 3146-3154.

- [5] A. Fernández, S. García, F. Herrera, and N. V. Chawla, "Smote for learning from imbalanced data: progress and challenges, marking the 15-year anniversary," *Journal of Artificial Intelligence Research*, vol. 61, pp. 863-905, 2018.

Nota importante:

Figuras y tablas

Cada figura debe ser leída y comprendida sin necesidad de recurrir a la descripción a lo largo del texto.

Todos los símbolos usados deben ser explicados en la leyenda.