"CLASIFICACIÓN DE LA POBREZA MONETARIA DE LOS HOGARES DE LIMA METROPOLITANA MEDIANTE APRENDIZAJE SUPERVISADO SOBRE MICRODATOS DE LA ENAHO"

Autores: Gael Sebastian Arias Escalante, Melanie Nadine Mallqui Huaraz, Valeshka del Pilar Lavado Guerra, Edilvan Franco Salcedo Enciso

Resumen—La pobreza monetaria de Lima Metropolitana se duplicó tras la pandemia y hoy concentra a cerca de un tercio de los pobres del país, mientras que buena parte de los hogares pobres no recibe apoyo de los programas sociales. Este trabajo plantea identificar a los hogares pobres sin medir su ingreso ni su gasto, mediante clasificadores supervisados entrenados con características observables de la vivienda, la composición del hogar, la educación y el empleo, tomadas de la Encuesta Nacional de Hogares. Se comparan una línea base econométrica, una regresión logística y ensambles de árboles, con aprendizaje sensible al costo, comparación de modelos a igual cobertura presupuestal, validación agrupada por conglomerado y evaluación fuera de tiempo que excluye a los hogares repetidos entre años. El objetivo es determinar si la mejora en la detección proviene de una representación más rica del hogar o de la complejidad del algoritmo, y si se mantiene de un año al siguiente.

Introducción

Descripción del problema: contexto, relevancia y justificación

En Lima Metropolitana, conformada por la Provincia de Lima y la Provincia Constitucional del Callao (`DOMINIO = 8` de la ENAHO), la pobreza monetaria pasó de 14.2 % de la población en 2019 a 28.2 % en 2024 [1]: unos 3.2 millones de personas cuyo gasto mensual no cubre la canasta básica de S/ 559.20. Según nuestra estimación con los microdatos de la ENAHO 2024, la capital reúne a un tercio de los pobres del país. A diferencia de la pobreza rural, la urbana se asocia a ingresos informales y volátiles, difíciles de verificar por los programas sociales, y a viviendas autoconstruidas: más del 90 % de la expansión urbana reciente en las principales ciudades del país fue informal [2].

Los programas sociales identifican a sus beneficiarios con *Proxy Means Tests* (PMT): puntajes calculados con características observables del hogar, porque medir el gasto de cada familia es inviable a gran escala. Estos instrumentos, calibrados habitualmente con regresiones lineales sobre el gasto, excluyen a una fracción considerable de los hogares pobres [3]. En Lima, el 67.2 % de los hogares pobres de la ENAHO 2024 (520 de 774) no registra transferencias monetarias públicas ni donaciones públicas de alimentos. Esta brecha de cobertura no se explica solo por el instrumento de focalización, pero muestra la magnitud del problema. Además, los indicadores clásicos de vivienda pierden poder en la ciudad: el 84.5 % de los hogares tiene paredes de ladrillo, y en ellos la pobreza es de 15.5 %, frente a 40.0 % en viviendas de madera o estera. El material discrimina, pero no basta.

El problema es relevante porque cada hogar pobre no identificado queda fuera de la protección social: se dispone de 8,219 hogares etiquetados (ENAHO 2024 y 2025) con datos públicos, ya descargados y parcialmente procesados. Por ello se formula como un problema de **clasificación binaria supervisada** sobre variables observables de vivienda, composición del hogar, educación y empleo, excluyendo el ingreso y el gasto. Un chequeo preliminar con validación agrupada por conglomerado en la ENAHO 2024 confirma que el problema no es trivial: un modelo solo con vivienda alcanza un área bajo la curva precisión-exhaustividad (PR-AUC) de 0.37, que sube a 0.56 al añadir los otros tres bloques.

Hipótesis y/o pregunta a abordar

Pregunta: ¿Qué tan eficazmente puede un clasificador basado en variables no monetarias de la ENAHO identificar a los hogares pobres de Lima Metropolitana, y qué factor aporta más a su desempeño: una caracterización multidimensional del hogar o la complejidad algorítmica del modelo, evaluada en un año posterior?

- **H1 (representación):** agregar demografía, educación y empleo a la vivienda aumenta la PR-AUC fuera de tiempo (2024→2025) en al menos 0.12.
- **H2 (algoritmo):** con las mismas variables y la misma cobertura presupuestal (20 % de hogares seleccionados), el error de exclusión del mejor ensamble de árboles difiere en menos de 3.5 puntos porcentuales del de los modelos lineales (PMT por mínimos cuadrados ordinarios, MCO, y regresión logística); se refuta si el intervalo de confianza al 95 % de la diferencia sale de ± 0.035.
- **H3 (operación):** existe un umbral de decisión con exhaustividad (*recall*) de al menos 0.70 y precisión de al menos 0.40 en 2025.
- **H4 (estabilidad temporal):** la PR-AUC cae como máximo 0.05 entre la validación de 2024 y la prueba de 2025.

Las metas se fijaron con la validación agrupada de 2024: ganancia de PR-AUC de 0.19, precisión de 0.45 con exhaustividad de 0.70 y errores de exclusión de 0.43 a 0.44 en los tres modelos con $B = 20\,\%$. La ENAHO 2025 se reserva para la prueba fuera de tiempo del informe final.

Objetivos

Objetivo general: desarrollar y evaluar comparativamente clasificadores supervisados que identifiquen a los hogares en pobreza monetaria de Lima Metropolitana con microdatos de la ENAHO, sin variables de ingreso ni gasto, priorizando un bajo error de exclusión y la estabilidad en el tiempo.

Objetivos específicos:

1. Construir un conjunto de datos a nivel hogar que integre los módulos 01, 02, 03, 05 y 34 de la ENAHO

para `DOMINIO = 8`, con la variable objetivo validada contra las cifras oficiales del INEI.

2. Diseñar operadores de agregación individuo→hogar que resuman la carga demográfica, el capital humano y la inserción laboral del hogar.

3. Entrenar y comparar una línea base PMT por MCO, una regresión logística regularizada, un árbol de clasificación, un *random forest* y un *gradient boosting*, con pérdida sensible al costo cuyo peso se trata como hiperparámetro.

4. Evaluar los modelos fuera de tiempo (2024→2025) sin los hogares panel repetidos, comparándolos con la misma cobertura presupuestal y mediante curvas de exclusión-inclusión, e interpretar sus predicciones con TreeSHAP.

Trabajos relacionados

McBride y Nichols [4] replicaron las herramientas PMT de USAID con encuestas de Bolivia, Timor-Leste y Malawi, y compararon modelos lineales elegidos por validación cruzada con *random forest* (RF) y *quantile regression forest* (QRF). La selección fuera de muestra mejoró el criterio balanceado de exactitud de pobreza (BPAC) entre 2.7 % y 17.5 % y redujo la subcobertura; además, el modelo paramétrico bien validado rindió igual o mejor que los ensambles. Como limitación, sus particiones aleatorias ignoran el diseño muestral y, según los propios autores, el método funciona fuera de muestra pero no fuera de población. Adoptamos su selección de modelos por validación y un comparador lineal fuerte.

Brown, Ravallion y van de Walle [3] evaluaron el PMT econométrico en nueve países africanos: con una pobreza de 20 %, el PMT por mínimos cuadrados excluye en promedio al 81 % de los pobres, y los estimadores centrados en la pobreza reducen esa exclusión a costa de más inclusión. No evalúan aprendizaje automático y su contexto es mayormente rural. Adoptamos el PMT sobre $\ln(\text{gasto})$ como línea base y la prioridad del error de exclusión.

Noriega-Campero et al. [5] reportan que la focalización con aprendizaje automático habría cubierto a casi un millón de pobres más en dos países sin elevar el gasto, aunque produce disparidades entre subgrupos si no se restringe. Mediante modelos de *gradient boosting*, mostraron que variar el umbral sobre el puntaje define una curva de intercambio exclusión-inclusión y que los pobres urbanos resultaron 2.3 veces más excluidos que los rurales. Evalúan con una sola partición aleatoria y sin validación temporal. Adoptamos la comparación a igual cobertura presupuestal y la auditoría por subgrupos.

Aiken, Ohlenburg y Blumenstock [6] analizaron diez años de encuestas de cuatro países africanos: los errores de un PMT aumentan 1.7 puntos porcentuales por año sin actualización, sobre todo por el cambio en las características de los hogares. Su evidencia proviene de PMT lineales en contextos no urbanos. Adoptamos la evaluación fuera de tiempo 2024→2025.

Asimismo, la literatura reciente sobre focalización respalda priorizar microdatos de encuesta frente a registros privados de telefonía, y confirma que los modelos de árboles constituyen el estado del arte en datos tabulares de tamaño moderado. La Tabla 1 resume la comparación.

Brecha de investigación. Los estudios revisados provienen de contextos mayormente rurales o de países africanos. Miden la estabilidad temporal solo con PMT lineales y no examinan en conjunto el desbalance de clases, la comparación a igual cobertura y la evaluación fuera de tiempo. Por su parte, los enfoques con datos de telefonía dependen de registros privados de difícil acceso para el Estado. No encontramos evaluaciones de este tipo para la pobreza urbana de Lima Metropolitana posterior a la pandemia con microdatos públicos de la ENAHO: ese es el vacío que aborda este trabajo.

Metodología

Formalización y comportamiento entrada/salida

Formalización del problema. Siguiendo el marco canónico de aprendizaje supervisado, se define la terna $\langle T, E, P\rangle$. La **tarea** T es inducir un clasificador $f : \mathcal{X} \to \{0,1\}$ que asigne a cada hogar i la etiqueta $y_i = \mathbb{I}(\texttt{POBREZA}_i \in \{1,2\})$, donde $\mathbb{I}(\cdot)$ es la función indicatriz (toma el valor 1 si la condición se cumple y 0 en caso contrario), agrupando pobreza extrema (código 1) y no extrema (código 2) como pobreza monetaria total frente a no pobre (código 3), según el Módulo 34 (Sumaria) del INEI. La **experiencia** E es la ENAHO 2024 de `DOMINIO = 8`: $N = 4{,}090$ hogares, de los cuales 774 son pobres (18.92 %), con razón de desbalance $\gamma \approx 4{,}28$. La prueba fuera de tiempo es la ENAHO 2025 sin los hogares panel: 3,199 hogares (17.4 % pobres). La **medida de desempeño** P incluye la PR-AUC, el error de exclusión $\mathrm{EE} = FN/(TP+FN)$ y el de inclusión $\mathrm{IE} = FP/(TP+FP)$ con cobertura fija B, exhaustividad, precisión y puntaje de Brier tras recalibración. Los modelos minimizan la pérdida logística sensible al costo:

$$\mathcal{L}(\theta) = -\frac{1}{N}\sum_{i=1}^{N}\left[\alpha\, y_i \ln \hat{p}_i + (1-y_i)\ln(1-\hat{p}_i)\right] + \lambda\,\Omega(\theta), \quad (1)$$

donde $\hat{p}_i = P(y_i = 1 \mid \mathbf{x}_i; \theta)$, Ω es la regularización y $\alpha \in \{1, 2, \gamma\}$ es un hiperparámetro elegido por validación (γ es un cociente de frecuencias, no un costo social). Rebalancear equivale a desplazar el umbral a $p^* = 1/(1+\alpha)$ [7], por lo que no se combinan ambas correcciones.

Espacio de entrada y salida. La entrada es $\mathbf{x}_i = [\mathbf{x}_i^{(\text{viv})}, \mathbf{x}_i^{(\text{dem})}, \mathbf{x}_i^{(\text{edu})}, \mathbf{x}_i^{(\text{emp})}] \in \mathbb{R}^{28}$, sin variables de ingreso ni gasto:

- Vivienda (Módulo 01): materiales, habitaciones, tenencia, agua, desagüe, combustible e internet.
- Demografía (Módulo 02): tamaño, menores, adultos mayores y dependencia; sexo y edad del jefe.
- Educación (Módulo 03): nivel del jefe y máximo del hogar.
- Empleo (Módulo 05): ocupados, categoría ocupacional, horas y pensión del jefe.

La salida es un puntaje continuo $\hat{p}_i$ (o el gasto predicho invertido en la línea base). La decisión selecciona al 20 % de hogares con mayor puntaje ($B = 0{,}20$), o aplica un umbral τ fijado en 2024 y congelado para 2025 (H3).

Ingeniería de datos, preprocesamiento y validación anti-fuga

Operador de reducción relacional Φ. La ENAHO posee estructura jerárquica (vivienda → hogar → individuo). Pa-

Tabla 1: Publicaciones evaluadas: datos, método, hallazgo principal, limitación y decisión que adopta el proyecto.

Estudio	Datos	Método	Hallazgo principal	Limitación	Adopción en el proyecto
McBride y Nichols (2018) [4]	Encuestas de Bolivia, Timor-Leste y Malawi (1,800–11,280 hogares)	MCO y regresión cuantílica con validación cruzada; RF y QRF	BPAC +2.7 % a +17.5 %; el lineal bien validado rinde como los ensambles	Partición aleatoria sin diseño muestral; variables preseleccionadas	Selección por validación; comparador lineal fuerte
Brown et al. (2018) [3]	Encuestas nacionales de 9 países africanos	PMT por MCO frente a estimadores centrados en la pobreza	Con pobreza de 20 %, el PMT excluye al 81 % de los pobres	Sin aprendizaje automático; contexto mayormente rural	Línea base PMT-MCO; prioridad del error de exclusión
Noriega-Campero et al. (2020) [5]	Encuestas de México, Ecuador y Costa Rica; dos países (2020)	*Gradient boosting*; curva exclusión-inclusión; umbrales por grupo	Casi un millón de pobres más cubiertos; pobres urbanos 2.3 veces más excluidos	Una sola partición aleatoria; sin validación temporal	Comparación a igual cobertura; auditoría por subgrupos
Aiken et al. (2023) [6]	10 años de encuestas de 4 países africanos	Entrenar en t y evaluar en $t+k$	+1.7 p.p. de error por año sin actualizar	PMT lineales; contextos no urbanos	Prueba fuera de tiempo 2024→2025

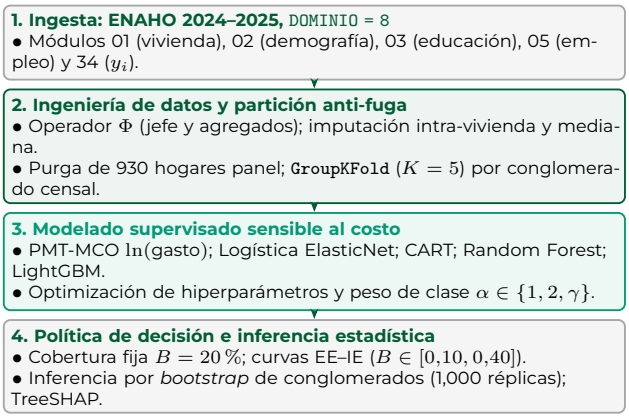


Figura 1: Flujo metodológico end-to-end. Φ: operador de reducción individuo→hogar; α: costo de la clase pobre; B: cobertura presupuestal; EE e IE: errores de exclusión e inclusión.

ra transformar los microdatos individuales en el vector de características del hogar $\mathbf{x}_i$, se define el operador relacional Φ con dos ramas [8]: (i) extracción de atributos del jefe del hogar ($P203 = 1$: edad, sexo, nivel educativo, horas semanales y afiliación a pensión); y (ii) funcionales de reducción sobre todos los miembros j, como la tasa de dependencia demográfica $\text{dep}_i = \sum_j \mathbb{I}(e_j < 15 \vee e_j \geq 65) / \max\big(1, \sum_j \mathbb{I}(15 \leq e_j < 65)\big)$, el hacinamiento (personas por habitación), el máximo nivel educativo alcanzado en el hogar y la fracción de ocupados.

Tratamiento de valores faltantes y atípicos. Se implementa un protocolo en dos fases: (a) *Imputación intra-vivienda*: 72 hogares secundarios (1.76 % en 2024) que comparten vivienda con el hogar principal carecen de datos físicos; estos atributos se heredan mediante propagación (*ffill/bfill*) restringida estrictamente al par (`CONGLOME`, `VIVIENDA`). (b) *Imputación en pipeline*: los nulos residuales numéricos se imputan por la mediana y las variables categóricas reciben una categoría sentinela (-1) ajustada exclusivamente en el conjunto de entrenamiento. Para evitar sesgar la muestra contra los hogares más vulnerables, **no se podan valores atípicos** en tamaño de hogar ni razón de dependencia; en su lugar, se preserva la distribución completa aprovechando la invarianza monotónica de los árboles y el escalamiento robusto en modelos lineales. Las categorías raras ($< 1\,\%$) se agrupan por afinidad antes del entrenamiento.

Protocolo anti-fuga y partición espacial. Para garantizar validez externa y evitar sobreestimación del desempeño, se aplican tres salvaguardas (Figura **??**): (i) *Partición fuera de tiempo (OOT)*: entrenamiento con 2024 y evaluación en 2025 [6]. (ii) *Purga de panel*: se identifican y eliminan del conjunto de prueba 2025 los 930 hogares repetidos encuestados en 2024, reduciendo la muestra de test a 3,199 hogares independientes. (iii) *Validación cruzada agrupada*: dado el diseño muestral bietápico del INEI por conglomerados censales (donde 702 de 704 conglomerados se repiten entre años), la validación interna emplea `GroupKFold` de 5 particiones agrupadas por `CONGLOME`, evitando fugas por autocorrelación espacial intra-clúster. Todo preprocesamiento opera encapsulado en un `Pipeline` ajustado únicamente en el fold de entrenamiento.

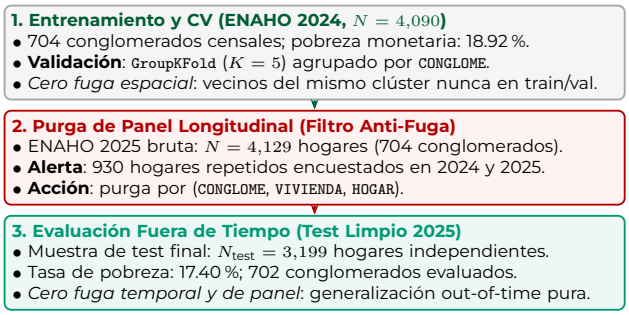


Figura 2: Protocolo de partición y blindaje anti-fuga en tres capas. Arriba: ENAHO 2024 con `GroupKFold` espacial. Centro: purga de 930 hogares panel. Abajo: conjunto de prueba independiente ($N_{\text{test}} = 3{,}199$).

Modelos supervisados, política de decisión e inferencia

Conjunto de modelos. Se comparan cinco algoritmos: (1) Línea base econométrica PMT-MCO sobre $\ln(\text{gasto}_i)$ [3, 4]; (2) Regresión logística regularizada con ElasticNet ($C \in [10^{-3}, 10^{2}]$, l_1-ratio $\in [0, 1]$); (3) Árbol de decisión CART con poda por costo-complejidad (α_{ccp}); (4) *Random Forest* (100 a 500 árboles, `max_depth` optimizado); y (5) LightGBM (tasa de aprendizaje $\eta \in [0{,}01, 0{,}1]$, `num_leaves` calibrado).

Política de asignación e inferencia. Para aislar el aporte algorítmico del umbral arbitrario, los modelos se comparan a una cobertura presupuestal fija $B = 20\,\%$, complementada con curvas exclusión-inclusión para $B \in [0{,}10, 0{,}40]$ [5]. La inferencia sobre las brechas entre mo-

delos (H1, H2, H4) se realiza mediante *cluster bootstrap* con 1,000 réplicas a nivel de conglomerado. Finalmente, se aplica TreeSHAP sobre el mejor ensamble para descomponer aditivamente los puntajes y auditar que las variables predictivas no capturen proxies prohibidos. Un chequeo preliminar en 2024 arrojó un EE de 0.43 a 0.44 para la línea base, la logística y *random forest*, con diferencias dentro de $\pm 0{,}035$ (H2). Las métricas se reportan por hogar y ponderadas por factor de expansión poblacional.

Tabla 2: Adaptaciones del enfoque y publicación que las sustenta.

Adaptación	Cómo se aplica	Sustento
Agregación del hogar (Φ)	Variables de jefatura y composición del hogar	[8]
Línea base PMT-MCO	$\ln(\text{gasto})$ con corte en la línea	[3, 4]
Pérdida sensible al costo	α como hiperparámetro; sin doble corrección del umbral	[7]
Igual cobertura y curva EE-IE	Selección de 20 % de hogares	[5]
Prueba fuera de tiempo sin panel	Entrenar 2024, evaluar 2025 sin 930 hogares	[6]
Validación agrupada	`GroupKFold` por conglomerado (diseño bietápico)	INEI [1]
Ensambles y explicabilidad	*Random forest*, LightGBM y TreeSHAP	[5]

Link del repositorio del trabajo

Repositorio público (no requiere credenciales), con el código del pipeline y la bitácora de observaciones, que incluye el código que reproduce las cifras del informe: `https://github.com/Ga3lAE/IA-Tarea-Academica`.

Declaración de contribución de cada integrante

Gael Sebastian Arias Escalante (20231149): arquitectura modular del pipeline de datos, validadores de esquema, formalización de la función de pérdida sensible al costo y edición del informe en LaTeX.

Valeshka del Pilar Lavado Guerra (20210761): revisión crítica de la literatura sobre *Proxy Means Testing*, procesamiento del Módulo 01 (vivienda) y diseño de la exclusión de hogares panel.

Melanie Nadine Mallqui Huaraz (20232374): diseño de la agregación individuo→hogar en demografía (Módulo 02) y empleo (Módulo 05), y regla de decisión con umbral y cobertura.

Edilvan Franco Salcedo Enciso (20203178): protocolo de validación fuera de tiempo (2024→2025) con validación agrupada por conglomerado, línea base PMT por mínimos cuadrados y redacción del marco experimental.

Declaración de uso de IA

Conforme a los lineamientos del sílabo, se declara el uso de asistentes de inteligencia artificial generativa (Claude, de Anthropic [9], y ChatGPT, de OpenAI [10]) para: (i) revisar y verificar la bibliografía contra sus fuentes originales; (ii) auditar el código y los cálculos sobre los microdatos de la ENAHO; y (iii) proponer borradores de redacción y de código en Python y LaTeX. Todas las cifras del informe se recalcularon con los scripts del repositorio, y los textos fueron revisados y editados por el grupo. Los registros de las conversaciones están disponibles si el docente los solicita. La responsabilidad del contenido final recae en los autores.

Referencias

[1] Instituto Nacional de Estadística e Informática, "Perú: Evolución de la pobreza monetaria, 2015–2024. Informe Técnico," INEI, Lima, Tech. Rep., May 2025. [Online]. Available: https://www.gob.pe/institucion/inei/informes-publicaciones/6763186-peru-evolucion-de-la-pobreza-monetaria-2015-2024

[2] Á. Espinoza and R. Fort, "Mapeo y tipología de la expansión urbana en el Perú," Grupo de Análisis para el Desarrollo (GRADE) y Asociación de Desarrolladores Inmobiliarios (ADI), Lima, Tech. Rep., 2020. [Online]. Available: https://www.grade.org.pe/wp-content/uploads/EspinozaFort_GRADEADI_expansionurbana.pdf

[3] C. Brown, M. Ravallion, and D. van de Walle, "A poor means test? Econometric targeting in Africa," *Journal of Development Economics*, vol. 134, pp. 109–124, 2018.

[4] L. McBride and A. Nichols, "Retooling poverty targeting using out-of-sample validation and machine learning," *The World Bank Economic Review*, vol. 32, no. 3, pp. 531–550, 2018.

[5] A. Noriega-Campero, B. Garcia-Bulle, L. F. Cantu, M. A. Bakker, L. Tejerina, and A. Pentland, "Algorithmic targeting of social policies: Fairness, accuracy, and distributed governance," in *Proc. 2020 Conference on Fairness, Accountability, and Transparency (FAT*)*, 2020, pp. 241–251.

[6] E. Aiken, T. Ohlenburg, and J. Blumenstock, "Moving targets: When does a poverty prediction model need to be updated?" in *Proc. 6th ACM SIGCAS/SIGCHI Conference on Computing and Sustainable Societies (COMPASS '23)*, 2023.

[7] C. Elkan, "The foundations of cost-sensitive learning," in *Proc. 17th International Joint Conference on Artificial Intelligence (IJCAI)*, 2001, pp. 973–978.

[8] M. Grosh, P. Leite, M. Wai-Poi, and E. Tesliuc, *Revisiting Targeting in Social Assistance: A New Look at Old Dilemmas*. Washington, DC: World Bank, 2022.

[9] Anthropic, "Claude [modelo de lenguaje de gran escala]," https://claude.ai, 2026, consultado en octubre de 2026.

[10] OpenAI, "ChatGPT [modelo de lenguaje de gran escala]," https://chatgpt.com, 2026, consultado en octubre de 2026.