

“CLASIFICACIÓN DE LA POBREZA MONETARIA DE LOS HOGARES DE LIMA METROPOLITANA MEDIANTE APRENDIZAJE SUPERVISADO SOBRE MICRODATOS DE LA ENAHO”

Autores: Gael Arias, Valeshka Lavado, Melanie Mallqui, Franco Salcedo

Resumen—La pobreza monetaria de Lima Metropolitana se duplicó tras la pandemia y hoy concentra a cerca de un tercio de los pobres del país, mientras que buena parte de los hogares pobres no recibe apoyo de los programas sociales. Este trabajo plantea identificar a los hogares pobres sin medir su ingreso ni su gasto, mediante clasificadores supervisados entrenados con características observables de la vivienda, la composición del hogar, la educación y el empleo, tomadas de la Encuesta Nacional de Hogares. Se comparan una línea base econométrica, una regresión logística y ensambles de árboles, con aprendizaje sensible al costo, comparación de modelos a igual cobertura presupuestal, validación agrupada por conglomerado y evaluación fuera de tiempo que excluye a los hogares repetidos entre años. El objetivo es determinar si la mejora en la detección proviene de una representación más rica del hogar o de la complejidad del algoritmo, y si se mantiene de un año al siguiente.

Introducción

Descripción del problema: contexto, relevancia y justificación

En Lima Metropolitana, conformada por la Provincia de Lima y la Provincia Constitucional del Callao ($\text{DOMINIO} = 8$ de la ENAHO), la pobreza monetaria pasó de 14.2 % de la población en 2019 a 28.2 % en 2024 [1]: unos 3.2 millones de personas cuyo gasto mensual no cubre la canasta básica de S/ 559.20. Según nuestra estimación con los microdatos de la ENAHO 2024, la capital reúne a un tercio de los pobres del país. A diferencia de la pobreza rural, la urbana se asocia a ingresos informales y volátiles, difíciles de verificar por los programas sociales, y a viviendas autoconstruidas: más del 90 % de la expansión urbana reciente en las principales ciudades del país fue informal [2].

Los programas sociales identifican a sus beneficiarios con *Proxy Means Tests* (PMT): puntajes calculados con características observables del hogar, porque medir el gasto de cada familia es inviable a gran escala. Estos instrumentos, calibrados habitualmente con regresiones lineales sobre el gasto, excluyen a una fracción considerable de los hogares pobres [3]. En Lima, el 67.2 % de los hogares pobres de la ENAHO 2024 (520 de 774) no registra transferencias monetarias públicas ni donaciones públicas de alimentos. Esta brecha de cobertura no se explica solo por el instrumento de focalización, pero muestra la magnitud del problema. Además, los indicadores clásicos de vivienda pierden poder en la ciudad: el 84.5 % de los hogares tiene paredes de ladrillo, y en ellos la pobreza es de 15.5 %, frente a 40.0 % en viviendas de madera o estera. El material discrimina, pero no basta.

El problema es relevante porque cada hogar pobre no identificado queda fuera de la protección social, y es abordable en un ciclo académico: se dispone de 8,219 hogares etiquetados (ENAHO 2024 y 2025) con datos públicos, ya descargados y parcialmente procesados. Por ello se formula como un problema de **clasificación binaria supervisada** sobre variables observables de vivienda, composición del hogar, educación y empleo, excluyendo el ingreso y el gasto. Un chequeo preliminar confirma que el problema no es trivial: un modelo solo con vivienda alcanza un área bajo la curva precisión-exhaustividad (PR-AUC) de 0.35, que sube a 0.55 al añadir los otros tres bloques.

Hipótesis y/o pregunta a abordar

Pregunta: ¿En qué medida un clasificador entrenado solo con variables no monetarias de la ENAHO identifica a los hogares pobres de Lima Metropolitana, y la ganancia proviene de una representación más rica del hogar o de la complejidad del algoritmo, manteniendo su desempeño en un año posterior?

- **H1 (representación):** agregar demografía, educación y empleo a la vivienda aumenta la PR-AUC fuera de tiempo (2024→2025) en al menos 0.12.
- **H2 (algoritmo):** con las mismas variables y la misma cobertura presupuestal (20 % de hogares seleccionados), el error de exclusión del mejor ensamble de árboles difiere en menos de 3 puntos porcentuales del de los modelos lineales (PMT por mínimos cuadrados y regresión logística); se refuta si el intervalo de confianza al 95 % de la diferencia sale de ± 0.03 .
- **H3 (operación):** existe un umbral de decisión con exhaustividad (*recall*) de al menos 0.70 y precisión de al menos 0.40 en 2025.
- **H4 (estabilidad temporal):** la PR-AUC cae como máximo 0.05 entre la validación de 2024 y la prueba de 2025.

Objetivos

Objetivo general: desarrollar y evaluar comparativamente clasificadores supervisados que identifiquen a los hogares en pobreza monetaria de Lima Metropolitana con microdatos de la ENAHO, sin variables de ingreso ni gasto, priorizando un bajo error de exclusión y la estabilidad en el tiempo.

Objetivos específicos:

1. Construir un conjunto de datos a nivel hogar que integre los módulos 01, 02, 03, 05 y 34 de la ENAHO para $\text{DOMINIO} = 8$, con la variable objetivo validada contra las cifras oficiales del INEI.
2. Diseñar operadores de agregación individuo→hogar que resuman la carga demográfica, el capital humano y la inserción laboral del hogar.
3. Entrenar y comparar una línea base PMT por mínimos cuadrados, una regresión logística regularizada, un *random forest* y un *gradient boosting*, con

pérdida sensible al costo cuyo peso se trata como hiperparámetro.

4. Evaluar los modelos fuera de tiempo (2024→2025) sin los hogares panel repetidos, comparándolos con la misma cobertura presupuestal y mediante curvas de exclusión-inclusión, e interpretar sus predicciones con TreeSHAP.

Trabajos relacionados

McBride y Nichols [4] replicaron las herramientas PMT de USAID con encuestas de Bolivia, Timor-Leste y Malawi, y compararon modelos lineales elegidos por validación cruzada con *random forest* y *quantile regression forest*. La selección fuera de muestra mejoró el criterio balanceado de exactitud de pobreza (BPAC) entre 2.7 % y 17.5 % y redujo la subcobertura; además, el modelo paramétrico bien validado rindió igual o mejor que los ensamblados. Como limitación, sus particiones aleatorias ignoran el diseño muestral y, según los propios autores, el método funciona fuera de muestra pero no fuera de población. Adoptamos su selección de modelos por validación y un comparador lineal fuerte.

Brown, Ravallion y van de Walle [3] evaluaron el PMT econométrico en nueve países africanos: con una pobreza de 20 %, el PMT por mínimos cuadrados excluye en promedio al 81 % de los pobres, y los estimadores centrados en la pobreza reducen esa exclusión a costa de más inclusión. No evalúan aprendizaje automático y su contexto es mayormente rural. Adoptamos el PMT sobre $\ln(\text{gasto})$ como línea base y la prioridad del error de exclusión.

Noriega-Campero et al. [5] reportan que la focalización con aprendizaje automático habría cubierto a casi un millón de pobres más en dos países sin elevar el gasto, aunque produce disparidades entre subgrupos si no se restringe. En su versión preliminar [6], el *gradient boosting* fue el mejor modelo, el umbral sobre el puntaje define una curva exclusión-inclusión y los pobres urbanos de Ecuador resultaron 2.3 veces más excluidos que los rurales. Evalúan con una sola partición aleatoria y sin validación temporal. Adoptamos la comparación a igual cobertura y la auditoría por subgrupos.

Aiken, Ohlenburg y Blumenstock [7] analizaron diez años de encuestas de cuatro países africanos: los errores de un PMT aumentan 1.7 puntos porcentuales por año sin actualización, sobre todo por el cambio en las características de los hogares. Su evidencia proviene de PMT lineales en contextos no urbanos. Adoptamos la evaluación fuera de tiempo 2024→2025.

Como apoyo, Aiken et al. [8] muestran que, con datos de telefonía, la exclusión baja entre 4 % y 21 % frente a la focalización geográfica pero sube entre 9 % y 35 % frente a un PMT con registro social, lo que respalda usar datos de encuesta; y Grinsztajn et al. [9] muestran que los árboles son el estado del arte en tablas de tamaño medio. La Tabla 1 resume la comparación.

Brecha de investigación. Los estudios revisados provienen de contextos mayormente rurales o de países africanos. Miden la estabilidad temporal solo con PMT lineales y no examinan en conjunto el desbalance de clases, la comparación a igual cobertura y la evaluación fuera de tiempo. Por su parte, los enfoques con datos de telefonía dependen de registros privados de difícil acceso para el Estado. No encontramos evaluaciones de este tipo para la pobreza urbana de Lima Metropolitana

posterior a la pandemia con microdatos públicos de la ENAHO: ese es el vacío que aborda este trabajo.

Metodología

Enfoque propuesto

Formalización del problema. Siguiendo a Mitchell [10], se define la terna $\langle T, E, P \rangle$. La **tarea** T es inducir $f : \mathcal{X} \rightarrow \{0, 1\}$ que asigne a cada hogar i la etiqueta $y_i = \mathbb{I}(\text{POBREZA}_i \in \{1, 2\})$, es decir, pobreza extrema o no extrema según el Módulo 34 (Sumaria) del INEI. La **experiencia** E es la ENAHO 2024 de DOMINIO = 8: $N = 4,090$ hogares, de los cuales 774 son pobres (18.92 %), con razón de desbalance $\gamma \approx 4.28$. La prueba fuera de tiempo es la ENAHO 2025 sin los hogares panel: 3,199 hogares (17.4 % pobres). La **medida de desempeño** P incluye la PR-AUC, el error de exclusión $EE = FN/(TP + FN)$ y el de inclusión $IE = FP/(TP + FP)$ con cobertura fija B , la exhaustividad, la precisión y el puntaje de Brier tras recalibrar las probabilidades. Los clasificadores minimizan una pérdida logística sensible al costo:

$$\mathcal{L}(\theta) = -\frac{1}{N} \sum_{i=1}^N [\alpha y_i \ln \hat{p}_i + (1 - y_i) \ln(1 - \hat{p}_i)] + \lambda \Omega(\theta), \quad (1)$$

donde $\hat{p}_i = P(y_i = 1 \mid \mathbf{x}_i; \theta)$, Ω es la regularización y $\alpha \in \{1, 2, \gamma\}$ es un hiperparámetro elegido por validación (γ es un cociente de frecuencias, no un costo social). Como reponderar equivale a desplazar el umbral de un modelo sin costos a $p^* = 1/(1+\alpha)$ [11], no se aplican ambas correcciones a la vez.

Comportamiento entrada/salida. La entrada es $\mathbf{x}_i = [\mathbf{x}_i^{(\text{viv})}, \mathbf{x}_i^{(\text{dem})}, \mathbf{x}_i^{(\text{edu})}, \mathbf{x}_i^{(\text{emp})}]$, con unas 30 variables:

- Vivienda (Módulo 01): materiales, habitaciones, tenencia, agua, desagüe, combustible e internet.
- Demografía (Módulo 02): tamaño, menores, adultos mayores y dependencia; sexo y edad del jefe.
- Educación (Módulo 03): nivel del jefe y máximo del hogar.
- Empleo (Módulo 05): ocupados, categoría ocupacional, horas y afiliación a pensión del jefe.

Ninguna variable de ingreso o gasto entra en $\mathbf{x}_i$; el gasto solo es la variable dependiente de la línea base. La salida es un puntaje por hogar ($\hat{p}_i$, o el gasto predicho con signo invertido en la línea base). La decisión selecciona al 20 % de hogares con mayor puntaje, que es la comparación principal, o usa un umbral τ fijado en la validación de 2024 y congelado para 2025 (H3).

Operadores y adaptaciones al problema. La Figura 1 muestra el flujo y la Tabla 2 su sustento en la literatura.

1. *Imputación intra-vivienda.* En 2024, 72 hogares secundarios (1.76 %) que comparten vivienda con el hogar principal no tienen datos físicos (paredes, pisos, habitaciones). Los heredan de su vivienda (CONGLOME, VIVIENDA) mediante relleno hacia adelante y atrás restringido a cada grupo, sin imputar valores globales.
2. *Agregación individuo→hogar.* Un operador Φ toma las personas j del hogar i y produce dos ramas: los atributos del jefe ($P203 = 1$) y funcionales del

Tabla 1: Publicaciones evaluadas: datos, método, hallazgo principal, limitación y decisión que adopta el proyecto.

Estudio	Datos	Método	Hallazgo principal	Limitación	Adopción en el proyecto
McBride y Nichols (2018) [4]	Encuestas de Bolivia, Timor-Leste y Malawi (1,800–11,280 hogares)	MCO y regresión cuantílica con validación cruzada; RF y QRF	BPAC +2.7 % a +17.5 %; el lineal bien validado rinde como los ensambles	Partición aleatoria sin diseño muestral; variables preseleccionadas	Selección por validación; comparador lineal fuerte
Brown et al. (2018) [3]	Encuestas nacionales de 9 países africanos	PMT por MCO frente a estimadores centrados en la pobreza	Con pobreza de 20 %, el PMT excluye al 81 % de los pobres	Sin aprendizaje automático; contexto mayormente rural	Línea base PMT-MCO; prioridad del error de exclusión
Noriega-Campero et al. (2020) [5,6]	Encuestas de México, Ecuador y Costa Rica; dos países (2020)	Gradient boosting; curva exclusión-inclusión; umbrales por grupo	Casi un millón de pobres más cubiertos; pobres urbanos 2.3 veces más excluidos	Una sola partición aleatoria; sin validación temporal	Comparación a igual cobertura; auditoría por subgrupos
Aiken et al. (2023) [7]	10 años de encuestas de 4 países africanos	Entrenar en t y evaluar en $t + k$	+1.7 p.p. de error por año sin actualizar	PMT lineales; contextos no urbanos	Prueba fuera de tiempo 2024→2025

- hogar, por ejemplo $\text{dep}_i = \sum_j \mathbb{I}(e_j < 15 \vee e_j \geq 65) / \text{máx}(1, \sum_j \mathbb{I}(15 \leq e_j < 65))$, donde e_j es la edad de la persona j . Se agregan el máximo nivel educativo, la proporción de ocupados y las personas por habitación.
3. *Agrupación de categorías raras ajustada solo en entrenamiento.* Las categorías con menos de 1 % se fusionan por afinidad. En pisos (2024): acabado noble 49.8 % de los hogares (pobreza 8.2 %), cemento 46.0 % (28.9 %) y precario 4.2 % (37.2 %). Las tasas se calculan solo con 2024 para evitar fuga de la etiqueta.
4. *Línea base econométrica.* PMT por mínimos cuadrados: $\ln(\text{gasto}_i) = \mathbf{w}^\top \mathbf{x}_i + \varepsilon_i$, con $\hat{y}_i = \mathbb{I}(\widehat{\ln \text{gasto}_i} < \ln \text{LINEA})$. Se compara con una regresión logística ElasticNet, un *random forest* y LightGBM [12], cuyos hiperparámetros se eligen por validación agrupada.
5. *Comparación a igual cobertura.* Todos los modelos seleccionan la misma proporción $B = 20\%$ de hogares, y se trazan curvas exclusión-inclusión para B entre 10 % y 40 %. Así se aísla el aporte del modelo de la elección del umbral.
6. *Protocolo contra la fuga de información.* (a) Se excluyen del test los 930 hogares de 2025 que también fueron encuestados en 2024. (b) La validación interna usa `GroupKFold` de 5 particiones por conglomerado, porque 702 de los 704 conglomerados se repiten entre años. (c) Codificación, escalamiento y agrupación de categorías se ajustan dentro de un `Pipeline` solo con datos de entrenamiento.
7. *Inferencia.* Las diferencias entre modelos (H1, H2, H4) se estiman con intervalos de confianza por *bootstrap* de conglomerados (1,000 réplicas), en lugar de la prueba de McNemar, que no compara PR-AUC ni FI.
8. *Interpretabilidad.* TreeSHAP [13] descompone el puntaje de cada hogar en contribuciones aditivas, $f(\mathbf{x}_i) = \phi_0 + \sum_{j=1}^d \phi_j(\mathbf{x}_i)$. Así se verifica que las variables más influyentes sean coherentes con la literatura y se detecta cualquier variable que filtre información del gasto.

Un chequeo preliminar con 28 variables, cuyo script está en el repositorio, dio $\text{EE} \approx 0,41$ con $B = 20\%$ para la línea base, la regresión logística y el *random forest*. Esto motiva formular H2 como una prueba de equivalencia.

Las métricas se reportan por hogar y, como robustez, ponderadas por personas ($\text{FACTOR07} \times \text{miembros}$).

Tabla 2: Adaptaciones del enfoque y publicación que las sustenta.

Adaptación	Cómo se aplica	Sustento
Línea base PMT-MCO	$\ln(\text{gasto})$ con corte en la línea	[3,4]
Pérdida sensible al costo	α como hiperparámetro; sin doble corrección del umbral	[11]
Igual cobertura y curva EE-IE	Selección de 20 % de hogares	[5]
Prueba fuera de tiempo sin panel	Entrenar 2024, evaluar 2025 sin 930 hogares	[7]
Validación agrupada	<code>GroupKFold</code> por conglomerado	[14]
Ensamblados de árboles	<i>Random forest</i> y LightGBM	[9,12]
Interpretabilidad	TreeSHAP por hogar	[13]




Figura 1: Flujo metodológico. y_i : pobreza oficial del hogar; Φ : agregación de personas a hogar; α : peso de la clase pobre en la pérdida; τ : umbral de decisión; B : proporción de hogares seleccionados; EE e IE: errores de exclusión e inclusión.

Link del repositorio del trabajo

Repositorio público (no requiere credenciales), con el código del pipeline, los scripts que reproducen todas las cifras del informe y la bitácora de observaciones: <https://github.com/Ga31AE/IA-Tarea-Academica>.

Declaración de contribución de cada integrante

Gael Arias: arquitectura modular del pipeline de datos, validadores de esquema, formalización de la función de pérdida sensible al costo y edición del informe en $\text{\LaTeX}$.

Valeshka Lavado: revisión crítica de la literatura sobre *Proxy Means Testing*, procesamiento del Módulo 01 (vivienda) y diseño de la exclusión de hogares panel.

Melanie Mallqui: diseño de la agregación individuo→hogar en demografía (Módulo 02) y empleo (Módulo 05), y regla de decisión con umbral y cobertura.

Franco Salcedo: protocolo de validación fuera de tiempo (2024→2025) con validación agrupada por conglomerado, línea base PMT por mínimos cuadrados y redacción del marco experimental.

Declaración de uso de IA

Se emplearon asistentes de inteligencia artificial (Claude, de Anthropic, y ChatGPT, de OpenAI) para: (i) revisar y verificar la bibliografía contra sus fuentes originales; (ii) auditar el código y los cálculos sobre los microdatos de la ENAHO; y (iii) proponer borradores de redacción y de código en Python y $\text{\LaTeX}$. Todas las cifras del informe se recalcularon con los scripts del repositorio, y los textos fueron revisados y editados por el grupo. La responsabilidad del contenido final recae en los autores.

Referencias

- [1] Instituto Nacional de Estadística e Informática, “Perú: Evolución de la pobreza monetaria, 2015–2024. Informe Técnico,” INEI, Lima, Tech. Rep., May 2025. [Online]. Available: <https://www.gob.pe/institucion/inei/informes-publicaciones/6763186-peru-evolucion-de-la-pobreza-monetaria-2015-2024>
- [2] Á. Espinoza and R. Fort, “Mapeo y tipología de la expansión urbana en el Perú,” Grupo de Análisis para el Desarrollo (GRADE) y Asociación de Desarrolladores Inmobiliarios (ADI), Lima, Tech. Rep., 2020. [Online]. Available: https://www.grade.org.pe/wp-content/uploads/EspinozaFort_GRADEADI_expansionurbana.pdf
- [3] C. Brown, M. Ravallion, and D. van de Walle, “A poor means test? Econometric targeting in Africa,” *Journal of Development Economics*, vol. 134, pp. 109–124, 2018.
- [4] L. McBride and A. Nichols, “Retooling poverty targeting using out-of-sample validation and machine learning,” *The World Bank Economic Review*, vol. 32, no. 3, pp. 531–550, 2018.
- [5] A. Noriega-Campero, B. Garcia-Bulle, L. F. Cantu, M. A. Bakker, L. Tejerina, and A. Pentland, “Algorithmic targeting of social policies: Fairness, accuracy, and distributed governance,” in *Proc. 2020 Conference on Fairness, Accountability, and Transparency (FAT*)*, 2020, pp. 241–251.
- [6] A. Noriega, B. Garcia-Bulle, L. Tejerina, and A. Pentland, “Algorithmic fairness and efficiency in targeting social welfare programs at scale,” in *Bloomberg Data for Good Exchange Conference*, New York, 2018.
- [7] E. Aiken, T. Ohlenburg, and J. Blumenstock, “Moving targets: When does a poverty prediction model need to be updated?” in *Proc. 6th ACM SIGCAS/SIGCHI Conference on Computing and Sustainable Societies (COMPASS '23)*, 2023.
- [8] E. Aiken, S. Bellue, D. Karlan, C. Udry, and J. E. Blumenstock, “Machine learning and phone data can improve targeting of humanitarian aid,” *Nature*, vol. 603, no. 7903, pp. 864–870, 2022.
- [9] L. Grinsztajn, E. Oyallon, and G. Varoquaux, “Why do tree-based models still outperform deep learning on typical tabular data?” in *Advances in Neural Information Processing Systems*, vol. 35, 2022, pp. 507–520.
- [10] T. M. Mitchell, *Machine Learning*. New York: McGraw-Hill, 1997.
- [11] C. Elkan, “The foundations of cost-sensitive learning,” in *Proc. 17th International Joint Conference on Artificial Intelligence (IJCAI)*, 2001, pp. 973–978.
- [12] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, “LightGBM: A highly efficient gradient boosting decision tree,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 3146–3154.
- [13] S. M. Lundberg, G. Erion, H. Chen, A. DeGrave, J. M. Prutkin, B. Nair, R. Katz, J. Himmelfarb, N. Bansal, and S.-I. Lee, “From local explanations to global understanding with explainable AI for trees,” *Nature Machine Intelligence*, vol. 2, no. 1, pp. 56–67, 2020.
- [14] D. R. Roberts, V. Bahn, S. Ciuti, M. S. Boyce, J. Elith et al., “Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure,” *Ecography*, vol. 40, no. 8, pp. 913–929, 2017.